

UNIVERSIDAD DE SAN CARLOS DE GUATEMALA
ESCUELA DE ESTUDIO POSTGRADO
MAESTRÍA EN INGENIERÍA PARA LA INDUSTRIA CON
ESPECIALIDAD EN CIENCIAS DE LA COMPUTACIÓN
CURSO: INTRODUCCIÓN A LA MINERÍA DE DATOS
CATEDRÁTICO: M.A. Ing. Kevin Lajpop



Proyecto fase 2

<https://github.com/jamesg19/data-mining-guatemala-mp-2024-2023>

James Osmin Gramajo Carcamo 999015976

INDICE

INTRODUCCION	3
ARBOLES DE DECISION	4
Arbol 1	4
Arbol 2	6
Arbol 3	8
RANDOM FOREST	14
1) Random Forest predicción del grupo de edad (g_edad_de0_80ymas)	14
2) Random Forest Predicción del sexo del Sindicado	16
3) Random Forest Predicción del sexo del Agraviado	18

INTRODUCCION

El presente reporte tiene como objetivo aplicar técnicas de minería de datos para analizar patrones de comportamiento delictivo en Guatemala durante los años 2023 y 2024, utilizando como base los registros de sindicados y agraviados.

Mediante el uso de algoritmos Arboles de decisiones, random forest y redes neuronales en Ry Python, se identificaron relaciones significativas entre variables como sexo, edad, departamento, mes y tipo de delito, con el propósito de generar conocimiento útil para la prevención del delito y la formulación de políticas públicas.

Se seleccionaron los datasets Sindicados 2024–2023 y Agraviados 2024–2023 debido a que los registros de los años 2020–2022 presentaban incompatibilidades en algunas columnas y diferencias en los diccionarios de variables. Por este motivo, se optó por utilizar los datos más recientes (2024–2023), garantizando así una estructura uniforme y una mayor coherencia para el análisis de clusters y reglas de asociación.

ARBOLES DE DECISION

Arbol 1

Data: data_sindicados_2024


Variables:

mes_hecho (*variable objetivo*)

g_edad_60ymas (*variable predictora*)

est_conyugal (*variable predictora*)

sexo_sindicados (*variable predictora*)



Fuente: RStudio (2025)

El árbol de decisión construido con rpart utilizó las tres variables predictoras anteriores para estimar el mes del hecho. La variable más influyente resultó ser g_edad_60ymas, dividiendo el modelo en perfiles claramente diferenciados.

Predicciones:

```
[1] "prediccion 1"
      1      2      3      4      5      6
1 0.04614329 0.04390622 0.04095329 0.09494124 0.1085426 0.09890831
      7      8      9     10     11     12
1 0.1038597 0.1014138 0.09601503 0.09523952 0.08488934 0.08518762
[1] "prediccion 2"
      1      2      3      4      5      6
1 0.2476921 0.2323991 0.2003834 0.1795576 0.06911879 0.03036834
      7      8      9     10     11
1 0.007346008 0.01022639 0.00793659 0.006796871 0.005025126
      12
1 0.003149769
```

Predicciones de los casos de prueba:

Conclusiones:

Caso 1

- $g_edad_60ymas = 11$
- $est_conyugal = 1$
- $sexo_sindicados = 1$

Las probabilidades se distribuyen relativamente uniformes, pero destacan: Mes 5 → 10.85%
Mes 7 → 10.38% Mes 8 → 10.14%

Esto sugiere que para personas en este perfil (edad relativamente baja, estado conyugal “soltero”, sexo “Hombre”), los hechos se concentran ligeramente entre **mayo y agosto**.

Caso 2

- $g_edad_60ymas = 12$
- $est_conyugal = 2$
- $sexo_sindicados = 2$

Aquí las probabilidades cambian drásticamente, indicando un patrón más definido:
Mes 1 → 24.7% Mes 2 → 23.2% Mes 3 → 20% Mes 4 → 17.9%

Esto muestra que, para individuos con valores altos en g_edad_60ymas , el modelo asocia los hechos delictivos principalmente a los primeros **cuatro meses del año(1-4)**.

Propuesta

Implementar acciones de prevención situacional focalizadas por mes y grupo demográfico, dado que ciertos perfiles como individuos con mayor edad codificada (categorías altas de g_edad_60ymas) concentran hechos en los primeros meses del año, se recomienda aplicar estrategias de prevención situacional durante esos periodos, tales como:

- Incremento de vigilancia en zonas de riesgo.
- Programas de proximidad policial.

Clarke, R. V. (1997). *Situational crime prevention: Successful case studies*. Harrow and Heston.

Arbol 2

Data: data_sindicados_2024-2023

Variables:

- dia_sem_hecho (variable objetivo)
- año_denuncia (predictora)
- dia_denuncia (predictora)
- mes_hecho (predictora)
- depto_ocu_hecho (predictora)

Ambos casos generan la misma distribución, lo cual confirma que únicamente “año_denuncia” está influyendo. Las probabilidades muestran alta dispersión entre categorías 1 a 7, con ligeras diferencias pero sin dominancia absoluta.



Predicciones:

```
[1] "prediccion 1"
      1      2      3      4      5      6      7
1 0.1802395 0.156194 0.1513717 0.1477822 0.1463344 0.108341 0.1096483
9
1 8.887691e-05
[1] "prediccion 2"
      1      2      3      4      5      6      7
1 0.1802395 0.156194 0.1513717 0.1477822 0.1463344 0.108341 0.1096483
9
1 8.887691e-05
```

Conclusion:

El modelo tiene bajo poder explicativo, dado que solo una variable (año_denuncia) separa la información. Esto indica que el día de la semana del hecho no presenta variación sistemática según las características temporales y espaciales incluidas.

Propuesta:

Enriquecer el modelo con variables contextuales como variables relacionadas mas a sindicados o agraviados como edad, profesión entre otras que han demostrado mejorar la predicción del día y hora de delitos (Mohler et al., 2015).

Mohler, G., Short, M., Brantingham, P., Schoenberg, F., & Tita, G. (2015). Randomized controlled field trials of predictive policing. *Journal of the American Statistical Association*, 110(512), 1399–1411.

Arbol 3

Archivo: data_sindicados_unida (2024-2023)

Variables:


G_edad_de0_80ymas Variable Dependiente

Sexo_sindicados (Predictoras)

Depto_ocu_hecho (Predictoras)

Est_conyugal (Predictoras)

g_edad_de0_80ymas Sindicados



Predicciones:

```
[1] "prediccion 1"
      1 2      3      4      5      6      7
1 0.01567449 0 0.003898319 0.05782506 0.1589377 0.1905303 0.1634045
      8      9      10      11      12      13
1 0.1103712 0.07894096 0.05092179 0.02785674 0.01673029 0.01218225
      14      15      16      17      18
1 0.006334768 0.005522618 0.002923739 0.00113701 0.09680825
[1] "prediccion 2"
      1 2 3      4      5      6      7
1 6.439979e-05 0 0 0.00634338 0.02959171 0.08307573 0.1492143
      8      9      10      11      12      13
1 0.1544951 0.1414541 0.1063563 0.07985574 0.05048944 0.03616048
      14      15      16      17      18
1 0.02282973 0.01230036 0.004733385 0.00309119 0.1199446
```


Nodo Raíz: La primera y más importante división se realiza con la variable sexo_sindicados.

- Regla 1 (rama izquierda, "yes"): Si sexo_sindicados < 6 (es decir cuando sea Hombre o Mujer), la clasificación continúa por esta rama.

Segundo Nivel: En la rama principal (izquierda), la siguiente división se realiza con la variable est_conyugal.

- Regla 3 (rama derecha): Si est_conyugal ≥ 5 , el árbol predice la clase 18 en rangos de edad no especificados
- Regla 4 (rama izquierda): Si est_conyugal < 5 , la clasificación continúa por esta rama.

Tercer Nivel: El subconjunto de casos restantes (est_conyugal < 5) se divide nuevamente usando est_conyugal. Esto sugiere que esta variable tiene múltiples categorías significativas:

- Regla 5 (rama derecha): Si est_conyugal 2 (pero aún < 5), el árbol predice la clase 8 (un grupo de edad) para estos 8 casos.
- Regla 6 (rama izquierda): Si est_conyugal < 2 (Soltero), la clasificación continúa por esta rama (7 casos).

Cuarto Nivel (Nodo Hoja Final): La última división utiliza depto_ocu_hecho.

- Regla 7 (rama derecha): Si depto_ocu_hecho ≥ 4 (Chimaltenango), el árbol predice la clase 18 en rangos de edad desconocidos.
- Regla 8 (rama izquierda): Si depto_ocu_hecho < 4 (Guatemala, Progreso, Sacatepéquez), el árbol predice 6 para los rangos de edad (25-29 años).

Propuesta

Modelo de Riesgo Dinámico y Enfoque de Equidad

Se propone desarrollar un Modelo de Riesgo Dinámico y de Equidad basado en los insights del árbol de decisión para optimizar la toma de decisiones.

Friedler, S. A., Scheidegger, C., & Weitzig, S. (Eds.). (2019). Fairness and Machine Learning. [Fairmlbook.org](https://fairmlbook.org)

Arbol 4

Datos: data_agraviados_unida (2024-2023)


Variables:

G_edad_de0_80ymas (Objetivo)

Sexo_agraviados (predictoras)

Depto_ocu_hecho (predictoras)

g_edad_de0_80ymas Agraviados



Predicciones:

```

[1] "prediccion 1"
      1      2      3      4      5      6
1 0.003655489 0.006427617 0.01427326 0.04144825 0.0846516 0.09765212
      7      8      9      10     11     12
1 0.09821003 0.0810426 0.07155809 0.05374557 0.04141919 0.02568722
      13     14     15     16     17     18
1 0.02039867 0.01400012 0.008473296 0.004870111 0.0040623 0.3284245
[1] "prediccion 2"
      1      2      3      4      5      6
1 0.006999089 0.01184461 0.03615506 0.06402717 0.09819432 0.1211795
      7      8      9      10     11     12
1 0.1205169 0.1016732 0.0880063 0.06013418 0.04129048 0.02497308
      13     14     15     16     17     18
1 0.01929926 0.0132113 0.008117287 0.004472791 0.005798062 0.1741075
  
```

Primer nodo: sexo_agraviados < 6

Dado que sexo_agraviados solo toma 1 o 2, esta división simplemente separa víctimas masculinas (1) y femeninas (2). Es decir, la variable sexo es el principal discriminador de las edades de las personas agraviadas.

Ramas principales

Rama izquierda (sexo = 1, masculino)

Luego la decisión depende del departamento donde ocurrió el hecho (depto_ocu_hecho).

Departamentos con valores más altos o más bajos tienden a concentrar más a ciertos grupos etarios, en algunos nodos intermedios aparece la regla:

- depto_ocu_hecho ≥ 11
- depto_ocu_hecho < 8

Esto significa que en ciertos departamentos (por ejemplo, los de código más alto), las víctimas masculinas tienden a pertenecer a un grupo etario específico.

Rama derecha (sexo = 2, femenino)

Para las mujeres, el modelo encuentra una distribución más homogénea, con varios nodos que asignan directamente el grupo de edad sin más particiones.

Esto sugiere que:

Predicción 1

sexo_agraviados = 1 (hombre)

depto_ocu_hecho = 1

Resultado:

El mayor valor corresponde al grupo 18 con probabilidad 0.3284.

Conclusión: Para un hombre víctima en el departamento 1, el modelo estima mayor probabilidad de que pertenezca al grupo de edad 18 (adulto mayor o categoría más alta definida en tu dataset).

Predicción 2

Entrada:

sexo_agraviados = 2 (mujer)

depto_ocu_hecho = 9 (Quetzaltenango)

El grupo 18 vuelve a tener la probabilidad más alta (0.1741) aunque menor que en el caso masculino.

Conclusión: En mujeres del departamento 9(Quetzaltenango), la distribución es más dispersa, pero el grupo 18 sigue siendo más probable, aunque no tan fuerte como en el caso masculino.

Propuesta:


Implementar sistemas de vigilancia focalizada y prevención diferenciada por territorio y sexo:

- Fortalecer sistemas de monitoreo en departamentos con mayor concentración de víctimas adultas o adultas mayores.
- Diseñar intervenciones preventivas específicas para hombres y mujeres, dado que el patrón de edad cambia según sexo.

Sherman, L. W. (2018). *Evidence-based policing: The theory and practice of smarter law enforcement*. Cambridge University Press.

RANDOM FOREST

1) Random Forest predicción del grupo de edad (g_edad_de0_80ymas)



Predicciones:

```
[1] 0.3188826
[1] "Test1"
  1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
1 0 0 0 0 0 1 0 0 0 0 0 0 0 0 0 0 0
attr("class")
[1] "matrix" "array" "votes"
[1] "Test2"
  1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
1 0 0 0 0 0 0 0.01 0.06 0.93 0 0 0 0 0 0 0 0
attr("class")
[1] "matrix" "array" "votes"
```

Interpretación de predicciones de prueba

Caso Test1

- sexo_sindicados = 1
- depto_ocu_hecho = 1

- est_conyugal = 1

Resultado:

El modelo asigna probabilidad 1 al grupo 35-39, lo cual indica una clasificación muy segura hacia esa categoría etaria.

Caso Test2


- sexo_sindicados = 2
- depto_ocu_hecho = 9
- est_conyugal = 2

Resultado:

El grupo **9(50-54 años)** concentra el 93% de la probabilidad, indicando confianza alta en esa clasificación.

Conclusión: Los grupos 35-39 y 50-54 son los más probables para los escenarios evaluados, mostrando que la edad del sindicato está influenciada principalmente por sexo y territorio.

2) Random Forest Predicción del sexo del Sindicato



Variable objetivo: sexo_sindicados

Variables predictoras: depto_ocu_hecho, mes_hecho.

Resultados generales

La matriz de confusión indica que:

- El modelo clasifica la mayoría de casos como sexo 1 (masculino).
- Las clases minoritarias (como categoría 9 si existe en tu dataset) reciben poca representación.

Precisión del modelo 2:

pre2 = 0.6794 (67.94%)

Interpretación de predicciones

Caso Test1

- depto_ocu_hecho = 1
- mes_hecho = 1

Resultado:

100% probabilidad de sexo 1 (masculino).

Caso Test2


- depto_ocu_hecho = 9
- mes_hecho = 12

Resultado:

también 100% probabilidad de sexo 1 (masculino).

Conclusión: Los patrones temporales y territoriales tienden a asociarse mayoritariamente con sindicatos masculinos, lo cual coincide con patrones criminológicos esperados.

3) Random Forest Predicción del sexo del Agraviado



Variables predictoras: depto_ocu_hecho, mes_hecho.

Resultados generales

La matriz de confusión muestra una distribución más equilibrada en comparación con el modelo anterior.

Precisión del modelo 3:
pre3 = 0.5165 (51.65%)

Interpretación de predicciones

Caso Test1

- depto_ocu_hecho = 1
- mes_hecho = 1

Resultado:
97% probabilidad de sexo 1 (masculino).

Caso Test2

- depto_ocu_hecho = 9
- mes_hecho = 12

Resultado:

93% probabilidad de sexo 2 (femenino).

Conclusión:

El modelo identifica que el sexo del agraviado varía dependiendo del departamento y del mes, mostrando patrones espacio-temporales diferenciados.

Propuesta:

Se recomienda implementar modelos predictivos continuos y sistemas de vigilancia criminológica territorial, integrando:

- Análisis temporal (mes del hecho).
- Análisis espacial (departamento).
- Análisis demográfico (sexo, estado conyugal, edad).

Estos modelos permiten focalizar recursos y diseñar intervenciones más precisas.

Diversos estudios han demostrado que el análisis predictivo mejora la capacidad institucional para anticipar patrones delictivos y orientar estrategias de prevención basadas en evidencia.

Referencias APA

- Braga, A. A., Papachristos, A. V., & Hureau, D. M. (2014). The effects of hot spots policing on crime: An updated systematic review and meta-analysis. *Justice Quarterly*, 31(4), 633–663.
- Sherman, L. W. (2018). *Evidence-based policing: The theory and practice of smarter law enforcement*. Cambridge University Press.

Redes Neuronales

Red neuronal 1

Predictoras:

- g_edad_60ymas
- est_conyugal
- sexo_sindicados

Variable objetivo: mes_hecho (13 categorías)

Resultados de la predicción

Entrada: [edad60más=9, estado conyugal=1, sexo=1]

Predicción

Los valores de probabilidad se distribuyen de forma muy pareja entre los 13 meses. No hay una categoría claramente dominante.

Métricas

- Loss: 2.4190
- Accuracy: 0.1235

Interpretación

- La red no logró aprender patrones relevantes con solo tres variables predictoras.
- La distribución casi uniforme en las probabilidades indica que el modelo está adivinando.
- La precisión del 12.3 % es similar a elegir al azar entre 13 meses (~7.7 %), aunque ligeramente mejor.

Red Neuronal 2

Predictoras:

- año_denuncia
- día_denuncia
- mes_hecho
- depto_ocu_hecho

Variable objetivo: día_sem_hecho (9 categorías)

Resultados de predicción

Se probaron dos escenarios:

Entrada 1:

[2024, 8, 5, 1]

[2023, 8, 5, 9]

Ambas predicciones fueron idénticas, mostrando que el modelo no distingue entre entradas distintas, lo cual es un signo claro de sobreentrenamiento.

La probabilidad más alta estuvo alrededor de 0.1856, sin dominancia marcada.

Métricas

Loss: 1.9170

Accuracy: 0.1854

Interpretación

La red no está captando diferencias temporales entre 2023 y 2024, ni la variación por departamento. El modelo probablemente está sobreajustado al promedio global, ignorando diferencias reales. El desempeño (18.5 %) sigue siendo bajo, aunque ligeramente mejor que la Red 1.

Red Neuronal 3

Predictoras:

- sexo_sindicados
- depto_ocu_hecho
- est_conyugal

Variable objetivo: grupo de edad (19 categorías)

Resultados de predicción

Entrada 1:

[1, 1, 2]

Salida: la predicción se concentró principalmente en probabilidades entre 0.13–0.16 para varias clases.

Entrada 2:

[2, 1, 2]

La distribución fue casi idéntica, con ligeros cambios.

Métricas

Loss: 1.9532

Accuracy: 0.4183

Interpretación

Este modelo presenta el mejor desempeño de los tres, con 41.8 % de exactitud, notablemente más alta considerando que existen 19 categorías posibles.

Las variables usadas, aunque pocas, sí correlacionan mejor con la edad del sindicado.

La red muestra señales de aprendizaje real, aunque aún no es óptima.

Conclusión

Es el modelo más prometedor. Con más variables y mayor limpieza de clases, puede alcanzar precisiones superiores que las redes anteriores.